

Synchronous Online Integral Reinforcement Learning

für zeitkontinuierliche Systeme

Vamvoudakis & Lewis (2011)

IEEE Transactions on Neural Networks, Vol. 22, No. 11

Freedy Fonou Nendou 913111 | **Majd Shahrour** 897392

Berliner Hochschule für Technik · Master Technische Informatik — Embedded Systems
WiSe 2025 · Gutachter: Prof. Dr.-Ing. Francisco Morales Serrano

Gliederung

Kontext & Motivation

Analyse der Contribution

Kritische Betrachtung & Eigene Simulationen

Problemdefinition

Mathematischer Rahmen — Warum ist dieses Problem schwierig?

Dynamisches System

$$\dot{x}(t) = f(x) + g(x) u(t), \quad x \in \mathbb{R}^n, \quad u \in \mathbb{R}^m$$

Gütefunktional

$$V(x_0) = \int_0^\infty [Q(x) + u^\top R u] dt, \quad Q \succ 0, \quad R \succ 0$$

Hamilton-Jacobi-Bellman (HJB)

$$Q(x) + u^\top R u + (\nabla V^*)^\top (f + g u^*) = 0$$

$$u^*(x) = -\frac{1}{2} R^{-1} g^\top(x) \nabla V^*$$

Kernproblem

Die HJB-Gleichung ist eine **nichtlineare PDE** — keine geschlossene Lösung im Allgemeinen.

Die optimale Politik $u^*(x)$ erfordert:

- ∇V^* — unbekannt
- $f(x)$ — Systemdynamik, oft unbekannt
- $g(x)$ — Eingangsmatrix, oft unbekannt

Ziel dieser Arbeit

Eine **modellfreie, Online-Methode** entwickeln, die V^* und u^* approximiert *ohne* Kenntnis von $f(x)$ und $g(x)$.

Stand der Technik

Warum scheitern bestehende Lösungen?

Methode	Online	Modellfrei	Kein ∇V^*	Synchron
PI offline (Abu-Khalaf 2005)	✗	✗	✗	✗
Actor-Critic online (Vamvoudakis 2010)	✓	✓	✗	✗
IRL offline (Vrabie 2009)	✗	✓	✓	✗
Online Sync. IRL (diese Arbeit, 2011)	✓	✓	✓	✓

Lücke in der Literatur

Keine bestehende Methode kombiniert alle vier Eigenschaften gleichzeitig. Dies ist das zentrale Argument der Autoren.

Schlüsselreferenzen

- Abu-Khalaf & Lewis (2005) — Policy Iteration offline
- Vrabie et al. (2009) — IRL offline
- Vamvoudakis & Lewis (2010) — Actor-Critic online

Warum Reinforcement Learning?

RL löst nicht dasselbe Problem besser — es löst ein realistischeres Problem

IRL-Umformulierung (Kernidee)

Statt HJB direkt zu lösen, integriere die Bellman-Gleichung über ein Zeitfenster $[t, t + T]$:

$$V(x(t)) = \int_t^{t+T} r(x, u) d\tau + V(x(t + T))$$

- $f(x)$ und $g(x)$ **nicht mehr benötigt**
- ∇V^* **nicht explizit berechnet**
- Linear in $\hat{W}_1 \Rightarrow$ lösbar per kleinste Quadrate

Persistente Erregung (PE)

Konvergenz garantiert, falls:

$$\alpha_m I \leq \int_t^{t+T} \Phi(x) \Phi^\top(x) d\tau \leq \alpha_M I$$

mit $0 < \alpha_m \leq \alpha_M$

Kritischer Hinweis

PE ist eine **notwendige Bedingung**, aber die Autoren formalisieren weder Amplitude noch Spektrum des Prüfrauschens, das PE sicherstellt.

Gütekriterien

Wie messen die Autoren den Erfolg?

Vier Konvergenzkriterien:

1. **Critic-Konvergenz:** $\hat{W}_1(t) \rightarrow W_1^*$
(Abb. 1 linear, Abb. 3 nichtlinear)
2. **Actor-Konvergenz:** $\hat{W}_2(t) \rightarrow \hat{W}_1$ bei Konvergenz
(synchrone Eigenschaft)
3. **Zustandsstabilität:** $x(t) \rightarrow 0$
(≈ 250 s linear; ≈ 80 s nichtlinear)
4. **Approximationsfehler:** $\varepsilon_V \approx 0$, $\varepsilon_u \approx 0$
(nur nichtlinearer Fall, Abb. 5, 6)

Kritische Einschränkung

Keine quantitativen Metriken

angegeben:

Die Autoren bewerten Konvergenz *ausschließlich visuell* (Grafiken) — keine Normen, kein RMSE, keine Konvergenzraten.

Dies erschwert einen objektiven Vergleich mit Referenzmethoden erheblich.

Der Algorithmus

Drei Kernkomponenten des synchronen Online-IRL

Komponente 1 — IRL-Umformulierung

Das Wertfunktional wird linear in $\hat{W}_1$ gemacht:

$$\phi^\top(x_k) \hat{W}_1 - \phi^\top(x_{k+1}) \hat{W}_1 = \int_{t_k}^{t_{k+1}} r \, d\tau$$

$\Rightarrow$ Kleinstquadrate-Problem in $\hat{W}_1$

Komponente 2 — Critic-Update (RLS)

$$\dot{\hat{W}}_1 = -\alpha_1 \Gamma \delta_{\text{IRL}} \phi(x)$$

mit $\delta_{\text{IRL}} = \text{IRL-Bellman-Fehler}$, $\Gamma = \text{Verstärkungsmatrix}$

Komponente 3 — Actor-Update (synchron)

$$\dot{\hat{W}}_2 = -\alpha_2 \left[\sigma \sigma^\top \hat{W}_2 + \frac{1}{2} R^{-1} g^\top \left(\frac{\partial \phi}{\partial x} \right)^\top \hat{W}_1 \right]$$

Synchron: Actor und Critic lernen *gleichzeitig*, kein sequenzieller Policy-Iteration-Schritt.

Theoretische Garantien

- Konvergenz $\hat{W}_1 \rightarrow W_1^*$ unter PE
- Stabilität des geschlossenen Regelkreises
- UUB-Nachweis via Lyapunov

Erzielen die Autoren eine bessere Lösung?

Theoretische vs. experimentelle Überlegenheit

Theoretisch: JA

Die Kombination aus vier Eigenschaften (Online, Modellfrei, kein ∇V^* , Synchron) ist **erstmalig in der Literatur**.

Rigide Lyapunov-Beweise garantieren Konvergenz und UUB-Stabilität.

Experimentell: NEIN

Kein direkter Vergleich auf denselben Benchmarks mit:

- Abu-Khalaf & Lewis (2005)
- Vrabie et al. (2009)

⇒ experimentelle Überlegenheit nicht nachgewiesen.

Numerische Validierung — F16, linearer Fall

	W_1^* (ARE)	$\hat{W}_1(t_f)$ (Online IRL)
w_1	1.4245	1.4279

Empfehlungen

Was würde ich ändern? — Vier konkrete Verbesserungsvorschläge

R1 — Prüfrauschen formalisieren

Amplitude und Spektrum des Prüfrauschens, das PE sicherstellt, sind nicht spezifiziert. Eine parametrische Analyse ist notwendig, um Reproduzierbarkeit zu gewährleisten.

R2 — Quantitative Metriken einführen

Bewertung ausschließlich via Grafiken ist unzureichend.

Vorschlag: $\|\hat{W}_1(t) - W_1^*\|_2$ und $\|\hat{u}(x) - u^*(x)\|_2$ über den Zustandsraum mitteln.

R3 — Skalierbarkeit testen

Quadratische Basis: $L = \frac{n(n+1)}{2}$ wächst quadratisch.

Für $n = 10$: $L = 55$ Terme. Nur niedrigdimensionale Benchmarks ($n = 2, 3$) getestet.

R4 — Direkter experimenteller Vergleich

Vergleich mit Abu-Khalaf (2005) auf denselben Benchmarks fehlt vollständig. Ohne diesen Vergleich ist die experimentelle Überlegenheit nicht belegbar.

Simulation 1 — PI-Sensitivität bezüglich K_0

Stützt Empfehlung R1: Einfluss der Initialisierung




Abbildung: Sensitivität der PI-Konvergenz bezüglich der Initialpolitik K_0

Konfiguration

F16-System, linearer Fall:

$$A \in \mathbb{R}^{3 \times 3}, \quad B \in \mathbb{R}^{3 \times 1}, \quad Q = I_3, \quad R = 1$$

Getestete K_0 :

- $0.05 \times K^*$
- $0.20 \times K^*$
- $0.50 \times K^*$

Ergebnis

Konvergenz in **2–3 Iterationen** für **alle** K_0 .

Endfehler: $\varepsilon \approx 5 \times 10^{-15}$

(Maschinengenauigkeit $\approx 2^{-52}$) ➔ Robust bezüglich K_0 .

Simulation 2 — Quantitative Metrik $\|\hat{W}_1^k - W_1^*\|_2$

Stützt Empfehlung R2: fehlende Normmessung in der Originalarbeit




Abbildung: Konvergenzmetrik $\|\hat{W}_1^k - W_1^*\|_2$ pro PI-Iteration — F16 linearer Fall

Metrik

$\varepsilon_k = \|\hat{W}_1^k - W_1^*\|_2$
 Berechnet nach jeder PI-Iteration k .
 W_1^* aus Riccati (ARE) bekannt.

Numerisches Ergebnis

$\varepsilon_{\text{final}} = 2,55 \times 10^{-15}$
 (Maschinengenauigkeit $\approx 2^{-52}$)
 Fehlende quantitative Validierung der Originalarbeit.

Wissenschaftliche Aussage

Eine Zahl wie $\varepsilon = 2,55 \times 10^{-15}$ ist aussagekräftiger als eine Kurve ohne Skala

Simulation 3 — Robustheit: PI vs. IRL bei Modellunsicherheit

Stützt Empfehlung R4: fehlender experimenteller Vergleich




Abbildung: Robustheit: PI offline mit gestörtem Modell vs. strukturelle Modellfreiheit von IRL

Szenario

Rauschen σ	PI-Fehler	IRL-Eigenschaft
0.00	0.0000	Modellfrei
0.05	≈ 0.33	Modellfrei
0.15	≈ 0.84	Modellfrei

Interpretation

PI mit gestörtem Modell divergiert mit zunehmendem σ .
IRL ist strukturell immun, da $f(x)$ **nicht** benötigt wird.

Zusammenfassung

- ✔ **Beitrag:** erste synchrone, Online, modellfreie IRL-Methode
- ✔ **Theorie:** Lyapunov-gesicherte Konvergenz und UUB-Stabilität
- ! **Grenzen:** kein experimenteller Vergleich, keine quant. Metriken, nur niedrig-dimensionale Benchmarks
- 🧪 **Eigene Sim.:** $\varepsilon_{\text{final}} = 2.55 \times 10^{-15}$ (Maschinengenaugkeit), Robustheit numerisch belegt

Vamvoudakis & Lewis (2011) — IEEE Trans. Neural Networks, Vol. 22, No. 11

Literaturverzeichnis I

-  K. G. Vamvoudakis and F. L. Lewis, *Online actor–critic algorithm to solve the continuous-time infinite horizon optimal control problem*, Automatica, vol. 46, pp. 878–888, 2010.
-  K. G. Vamvoudakis and F. L. Lewis, *Synchronous Online Integral Reinforcement Learning for Continuous-Time Systems*, IEEE Trans. Neural Networks, vol. 22, no. 11, pp. 1764–1775, Nov. 2011.
-  M. Abu-Khalaf and F. L. Lewis, *Nearly optimal control laws for nonlinear systems with saturating actuators using a neural network HJB approach*, Automatica, vol. 41, pp. 779–791, 2005.
-  D. Vrabie, O. Pastravanu, M. Abu-Khalaf, and F. L. Lewis, *Adaptive optimal control for continuous-time linear systems based on policy gradient*, Automatica, vol. 45, pp. 477–484, 2009.